
20170616 정희진

* Because I submitted late, I will use 2 tokens.

1. Clustering

(a) Solve the following problem, which is based on the exercises in the Mining of Massive Datasets 2nd edition (MMDS) textbook.

A set of strings: [abc, abcde, abcfghijk, abcdfghl] 이 있다고 하자. 그렇다면 각 edit distance는 다음과 같다.



각 점의 distance의 합을 구해보면 다음과 같다.

abc	abcde	abcfghijk	abcdfghl	
13	15	19	15	

각 점의 maximum distance를 구해보면 다음과 같다.

abc	abcde	abcfghijk	abcdfghl
6	8	8	5

따라서 clustroid와 다른 점들과의 distance의 합을 최소화하도록 clustroid를 고르면 abc가 된다.


하지만 clustroid와 다른 점들과의 distance 중 maximum distance를 최소화하도록 clustroid를 고르면 abcdfghl이 된다.

(b) Implement the k-Means algorithm using Spark

각 number of cluster에 대한 average diameter은 다음과 같다.

k (Number of cluster)	Average diameter
1	15840.015935162377
2	8712.758000610926
3	4225.773466007263
4	2018.267391109598
5	1526.2137994123182
6	1420.7214130743844
8	1003.3225742993732
16	504.6115133174929

위의 표를 그래프로 그리면 다음과 같다.



처음에는 k = 1, 2, 4, 8, 16일 때의 average diameter를 구했다. 이때, k = 8일 때와 k = 16일 때 많은 변화가 없으므로 k가 8보다 작을 때 변화가 큰 지점이 있다는 것을 알 수 있었다. 따라서 추가적으로 k = 3, 5, 6일 때의 average diameter를 구했다. 그래프를 보면 k = 4일 때 가장 큰 변화가 일어난다. k = 4일 때 변화가 가장 크게 일어나는지 알아보기 위해 다음의 식을 계산해보았다.

k = m - 1일때와 k = m일 때의 average diameter 차이

m	3	4	5	6
Α	4486.985	2207.506	492.0536	105.4924

M=3,4일 때는 변화량이 1000 이상이지만 그 이후부터 1000 미만이 된다. 따라서 k=4일 때가장 적절하게 군집될 것이다.


2. Dimensionality Reduction

Exercise 11.1.7


문제를 풀기 위한 python 코드는 다음과 같다.

```
import numpy as np
M = np.array([[1,1,1],[1,2,3],[1,3,6]])
x = np.array([[1,1,1]]).T
for i in range(3):
    print("####### Finding %dth eigenpair ######" %(i+1))
    print("Matrix is")
    print(M)
    for j in range(10):
        Mx = np.matmul(M, x)
        x = Mx/ np.linalg.norm(Mx)
         print("x%d" %(i+1),"is") # Check the value change
         print(x)
    eig_vec = x
    print("Eigenvector is")
    print(eig_vec)
    eig_val = np.matmul(np.matmul(eig_vec.T, M), eig_vec)
    print("Eigenvalue is")
    print(eig_val)
    M = M - eig_val * np.matmul(eig_vec, eig_vec.T)
    x = np.array([[1,1,1]]).T
```

(a) Starting with a vector of three 1's, use power iteration to find an approximate value of the principal eigenvector.



(b) Compute an estimate the principal eigenvalue for the matrix.



(c) Construct a new matrix by subtracting out the effect of the principal eigenpair, as in Section 11.1.3.

```
Matrix is
[[ 0.70423389  0.27936833 -0.31216389]
[ 0.27936833  0.24418694 -0.19707639]
[-0.31216389 -0.19707639  0.17859583]]
```

(d) From your matrix of (c), find the second eigenpair for the original matrix of Exercise 11.1.5.

```
Eigenvector is
[[ 0.81649658]
[ 0.40824829]
[-0.40824829]]
Eigenvalue is
[[1.]]
```

(e) Repeat (c) and (d) to find the third eigenpair for the original matrix.

문제를 풀기 위한 전체 python 코드는 다음과 같다.

```
import numpy as np
M = np.array([[1,2,3],[3,4,5],[5,4,3],[0,2,4],[1,3,5]])
MTM = np.matmul(M.T, M)
MMT = np.matmul(M, M.T)
print("MTM is")
print(MTM)
print("MMT is")
print(MMT)
print("(b)#############################")
w1, v1 = np.linalg.eig(MTM)
print("MTM eigenvalues are")
print(w1)
print("MTM eigenvectors are")
print(v1)
w2, v2 = np.linalg.eig(MMT)
print("MMT eigenvalues are")
print(w2)
print("MMT eigenvectors are")
print(v2)
print("(c)#############################")
U = v2[:,[0,2]]
S = np.zeros((2,2))
np.fill_diagonal(S, (w1[0:2])**(1/2.0))
```

```
V = v1[:,0:2]
print("M is")
print(M)
print("But USV.T is")
print(np.matmul(np.matmul(U, S),V.T))
U = -1 * U
print("U is")
print(U)
print("S is")
print(S)
print("V is")
print(V)
print("Now USV.T is")
print(np.matmul(np.matmul(U, S), V.T))\\
new_U = U[:,[0]]
new_S = S[0,0]
new_V = V[:,[0]]
print("Reduced U is")
print(new_U)
print("Reduced S is")
print(new_S)
print("Reduced V is")
print(new_V)
new_M = new_S * np.matmul(new_U, new_V.T)
print("Reduced M is")
```

(a) Compute the matrices $M^TM(MTM)$ and $MM^T(MMT)$.

```
MTM is

[[36 37 38]

[37 49 61]

[38 61 84]]

MMT is

[[14 26 22 16 22]

[26 50 46 28 40]

[22 46 50 20 32]

[16 28 20 20 26]

[22 40 32 26 35]]
```

(b) Find the eigenpairs (eigenvalues, eigenvectors) for your matrices of part (a) using Python NumPy function (numpy.linalg.eig()).

```
MTM eigenvalues are
[1.53566996e+02 1.54330035e+01 6.69501359e-15]
MTM eigenvectors are
[[-0.40928285 -0.81597848 0.40824829]
[-0.56345932 -0.12588456 -0.81649658]
[-0.7176358 0.56420935 0.40824829]]
```

- (c) Find the SVD for the original matrix M from parts (b). Note that there are only two nonzero eigenvalues, so your matrix $\Sigma(S)$ should have only two singular values, while U and V have only two columns.
- U, Σ, V를 계산했지만, 실제로 UΣV.T를 계산해보니 -1*M이 나왔다. 이는 위에서 계산한 eigenvector의 (크기만 1일 뿐) 첫번째 element가 음수의 값을 가질 수도, 양수의 값을 가지게 나타날 수 있기 때문이다.

```
M is
[[1 2 3]
[3 4 5]
[5 4 3]
[0 2 4]
[1 3 5]]
But USV.T is
[[-1.000000000e+00 -2.00000000e+00 -3.00000000e+00]
[-3.00000000e+00 -4.00000000e+00 -5.00000000e+00]
[-5.00000000e+00 -4.00000000e+00 -3.00000000e+00]
[ 1.11022302e-15 -2.000000000e+00 -4.000000000e+00]
[ -1.000000000e+00 -3.000000000e+00 -5.000000000e+00]
```

따라서 다음과 같은 코드를 넣어 다시 계산해 보았다.

```
U = -1 * U
```

결과는 M과 비슷하게 나왔다.

```
Now USV.T is
[[ 1.00000000e+00 2.00000000e+00 3.00000000e+00]
  [ 3.00000000e+00 4.00000000e+00 5.000000000e+00]
  [ 5.00000000e+00 4.00000000e+00 3.00000000e+00]
  [-1.11022302e-15 2.00000000e+00 4.00000000e+00]
  [ 1.00000000e+00 3.00000000e+00 5.000000000e+00]]
```

따라서 U, Σ(S), V는 다음과 같다.

(d) Set your smaller singular value to 0 and compute the one-dimensional approximation to the matrix M.

Dimension을 줄이기 위해 U, $\Sigma(S)$, V를 다음처럼 보정했다.

```
Reduced U is
[[-0.29769568]
        [-0.57050856]
        [-0.52074297]
        [-0.32257847]
        [-0.45898491]]
Reduced S is
12.39221515549012
Reduced V is
[[-0.40928285]
        [-0.56345932]
        [-0.7176358]]
```

위에서 구한 U, $\Sigma(S)$, V를 가지고 M을 구하면 다음과 같다.

```
Reduced M is

[[1.509889     2.0786628     2.64743661]

[2.89357443     3.98358126     5.0735881 ]

[2.64116728     3.63609257     4.63101787]

[1.63609257     2.25240715     2.86872172]

[2.32793529     3.20486638     4.08179747]]
```

(e) How much of the energy of the original singular values is retained by the onedimensional approximation? (Hint: energy = sum of the squares of the singular values)

The retained energy is 90.868045%

2. Recommendation Systems

	a	b	c	d	e	f	g	h	는제 플이에서 Jaccord ()는 Jaccord similarly	
\overline{A}	4	5		5	1		3	2	Cosine() & cosine Similarity Soccord listal elemental 34000 Bib Jacord similarity & 4644	-
B		3	4	3	1	2	1			
C	2		1	3		4	5	3		

Exercise 931

(a) Jaccard (A,B)=
$$\frac{4}{8} = \frac{1}{2}$$
 Distance (A,B)= $|-\frac{1}{2} = 05$

Jaccard (B,C) =
$$\frac{4}{8} = \frac{1}{2}$$
 Distance (B,C)= $1 - \frac{1}{2} = 0.5$

Jaccard (A,C)=
$$\frac{4}{8}$$
= $\frac{1}{2}$ Distance (A,C)= $\frac{1}{2}$ =05

(b) Cosine (A.B) =
$$\frac{5 \times 3 + 5 \times 3 + |x| + 3 \times 1}{\sqrt{4^2 + 5^2 + 5^2 + 1^2 + 3^2 + 2^2}} = \frac{34}{3^2 + 4^2 + 3^2 + 1^2 + 2^2 + 1^2} = \frac{34}{80 \sqrt{40}} = \frac{17}{40}$$
Distance (A.B) = $\cos^4(\frac{17}{40}\sqrt{2}) = 0.926$

$$Cosine(B,C) = \frac{4 \times 15^{3} + 3^{2} + 1^{2} + 1^{4} + 3^{4} + 1^{4} + 2^{4} + 1^{4} +$$

Distance(B,C)=
$$\cos^4(\frac{13}{80}\pi0)=1.031$$

$$Cosine(A.c) = \frac{4 \times 2 + 5 \times 3 + 3 \times 5 + 2 \times 3}{\sqrt{4^2 + 5^2 + 5^2 + 1^2 + 3^2 + 2^2 + 2^2 + 2^2 + 1^2 + 3^2 + 1^2 + 5^2 + 5^2}} = \frac{4 \times 4}{\sqrt{80} \sqrt{64}} = \frac{11}{40} \sqrt{5}$$

Jaccard (A,B)=
$$\frac{2}{5}$$
 Distance (A,B)= $1-\frac{2}{5}=\frac{1}{5}$

Jaccard (B,C)=
$$\frac{1}{6}$$
 Distance (B,C)= $\frac{1}{6}$ = $\frac{1}{6}$

Jaccard (A,C)=
$$\frac{2}{6} = \frac{1}{3}$$
 Distance (A,C)= $1 - \frac{1}{3} = \frac{2}{3}$

Cosine (A,C) =
$$\frac{|x|+|x|}{\sqrt{|x'+|x'|^2}\sqrt{|x'+|x'|^2}} = \frac{2}{4} = \frac{1}{2}$$
 Distance (A,C) = COS ($\frac{1}{2}$) = 1.047

(e) mean
$$A = \frac{4+5+5+1+3+2}{6} = \frac{20}{6} = \frac{10}{3}$$

mean B =
$$\frac{3+4+3+1+2+1}{6} = \frac{14}{6} = \frac{7}{3}$$

Mean
$$C = \frac{2+113+4+5+3}{6} = \frac{18}{6} = 3$$

	a	b	c	d	e	7	9	h
Α	23	53		5/3	-23		-==	-43
В	-	2	5/3	23	-4/3	-1/3	-43	
c	-1		-2	0		1	2	0

$$(f) Cosine (A,B) = \frac{\frac{1}{3} \times \frac{2}{3} + \frac{5}{3} \times \frac{2}{3} + (-\frac{9}{3}) \times (-\frac{4}{3}) + (-\frac{1}{3}) \times (-\frac{4}{3})}{\sqrt{(\frac{2}{3})^2 + (\frac{1}{3})^2 + (\frac{1}{3})^2 + (-\frac{1}{3})^2 + (-\frac{4}{3})^2}} = \frac{\frac{52}{9}}{\sqrt{\frac{120}{9}} \sqrt{\frac{66}{9}}} = \frac{13}{165} \sqrt{55}$$

$$Cosine(B,C) = \frac{\frac{5}{3} \times (-2) - \frac{1}{3} \times 1 - \frac{4}{3} \times 2}{\sqrt{(\frac{2}{3})^2 + (\frac{5}{3})^2 + (\frac{2}{3})^2 + (\frac{-1}{3})^2 + (\frac{-4}{3})^2}} \sqrt{(-1)^2 + (-2)^2 + (-1)^2 + (-2)^2} = \frac{-\frac{19}{3}}{\sqrt{\frac{66}{9}} \sqrt{60}} \sqrt{\frac{66}{9}} \sqrt{\frac$$

$$Cosine(A,B) = \frac{\frac{2}{3}x(-1) - \frac{1}{3}x2}{\sqrt{\frac{(2)^{2}}{3}!} + (\frac{1}{3})^{2}!} + (\frac$$

Distance (A,B) =
$$\cos^{1}(\frac{13}{165}\sqrt{15}) = 0.947$$

Distance (B,C) = $\cos^{1}(\frac{-19}{660}\sqrt{660}) = 2.403$
Distance (A,C) = $\cos^{1}(-\frac{13}{15}) = 1.687$

Exercise 932

(a)		a	Ь	c	d	e	4	9	h
	Α	1	1	0	1	0	0	1	0
	В	0	1	1		0	0	0	0
	c	0	0	0	T	0	П	1	1

Jaccard list = $[(a,b,\frac{1}{2}),(a,c,o),(a,d,\frac{1}{3}),(a,e,o),(a,f,o),(a,g,\frac{1}{2}),(a,h,o),(b,c,\frac{1}{2}),(b,d,\frac{2}{3}),(b,e,o),(b,f,o),(c,d,\frac{1}{3}),(c,e,o),(c,f,o),(c,g,o),(c,h,o),(d,e,o),(d,f,\frac{1}{3}),(d,f,\frac{1}{3}),(d,f,\frac{1}{3}),(d,f,\frac{1}{3}),(d,f,\frac{1}{3}),(d,f,\frac{1}{3}),(e,f,o),(e,g,o),(e,h,o),(f,g,\frac{1}{2}),(f,f,1),(g,f,\frac{1}{2})]$

Jaccard Similarity가 1일 때가 가장 높으므로 가장 먼저 f.h가 한 cluster가 될 것이다.
다음으로 similarity가 을 할 때 가장 높으므로 b.d.g가 한 cluster가 될 것이다.
다음으로 similarity가 글일때 가장 높다. (a.b.늘). (a.g.늘). (b.c.늘). (f.g.늘)이 있는데, 이 순서대로 우선 순위를 들다면 ((a.b.늘)가 우선 순위가 가장 높다면) a.b.d.g가 한 cluster가 된다.
cluster (a.b.d.g., cluster 2 C, cluster 3 e, cluster 4 f.h


(c) Cosine(A,B) =
$$\frac{\frac{19}{4} \times \frac{9}{3} + |x| + 2 \times 2}{\sqrt{(\frac{19}{4})^2 + 1^2 + 2^2} \sqrt{(\frac{9}{3})^2 + 4^2 + 1^2 + 2^2}} = 0.604 \quad \text{Distance}(A,B) = \cos^4(0.604) = 0.922$$

$$\text{Cosine}(B,C) = \frac{\frac{9}{3} \times \frac{9}{3} + 4 \times 1 + 2 \times \frac{9}{2}}{\sqrt{(\frac{9}{3})^2 + 4^2 + 1^2 + 2^2} \sqrt{(\frac{9}{3})^2 + 1^2 + (\frac{9}{2})^2}} = 0.940 \quad \text{Distance}(B,C) = \cos^4(0.940) = 0.938$$

$$\text{Cosine}(A,C) = \frac{\frac{19}{4} \times \frac{9}{3} + 2 \times \frac{9}{2}}{\sqrt{(\frac{19}{4})^2 + 1^2 + 2^2} \sqrt{(\frac{9}{3})^2 + 1^2 + (\frac{9}{2})^2}} = 0.893 \quad \text{Distance}(A,C) = \cos^4(0.893) = 0.469$$

(b) Implement collaborative filtering

User-based Result



Item-base Result는 정상적으로 작동하는 것 같으나 시간이 오래 걸려 구하지 못했다.